

# Rețele neuronale și deep learning

## Cursul 6: Bazele NLP: reprezentarea textului și reprezentarea vectorială a cuvintelor



**Prof. dr. Daniel Traian PELE**

Academia de Studii Economice din București (ASE), Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică (IPE)
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

# Obiectivele cursului

- Să transformați textul financiar în numere pentru prelucrarea limbajului natural (NLP): unități lexicale, vocabular, sac de cuvinte și frecvența termenului–frecvența inversă în documente (TF-IDF).
- Să scrieți funcțiile-obiectiv ale word2vec și GloVe și să le antrenați pe un corpus real de discursuri ale băncii centrale.
- Să construiți clasificatoare de fraze din reprezentări rare și dense, cu modele de referință și teste corecte.
- Să măsurați sentimentul și temele financiare în știri și tweet-uri și să știți cînd un model liniar este suficient.

# Abrevieri

| | |
|---|---|
| **AI** | inteligență artificială |
| **ASE** | Academia de Studii Economice din București |
| **BCE** | Banca Centrală Europeană |
| **BERT** | reprezentări bidirecționale ale codificatorului transformer (BERT) |
| **BoW** | sac de cuvinte (bag of words) |
| **CBOW** | sac continuu de cuvinte (varianta word2vec) |
| **CPU** | procesor central |
| **ES** | pierderea medie așteptată peste VaR (expected shortfall) |
| **ESG** | mediu, social și guvernanță |
| **FinBERT** | model BERT adaptat textelor financiare |
| **IPE** | Institutul de Prognoză Economică, Academia Română |
| **LLM** | model lingvistic mare |
| **MLP** | perceptron multistrat |
| **NLP** | prelucrarea limbajului natural |
| **OOV** | în afara vocabularului |
| **PCA** | analiza componentelor principale |
| **PMI** | informația mutuală punctuală |
| **SGNS** | skip-gram cu eșantionare negativă |
| **SVD** | descompunerea în valori singulare |
| **TF-IDF** | frecvența termenului–frecvența inversă în documente |
| **VaR** | valoarea expusă la risc (value-at-risk) |

# Numai date reale: trei colecții de texte

| Corpusul | Conținut | Dimensiune | Utilizare aici |
|---|---|---|---|
| Financial PhraseBank | fraze din știri financiare despre companii listate în Finlanda, etichetate pozitiv / neutru / negativ de 5–8 adnotatori | 4 838 de fraze | sentiment |
| Twitter financial news | tweet-uri financiare: pesimist / optimist / neutru și 20 de teme | 9 543 + 2 388 (sentiment), 16 990 + 4 117 (teme) | sentiment, teme |
| Discursurile Băncii Centrale Europene (BCE) | textele integrale ale membrilor Comitetului executiv și ai Consiliului de supraveghere | 400 de discursuri, 1 289 896 de unități lexicale | propriii noștri vectori de cuvinte |

- Discursuri din perioada 8 ianuarie 2022 – 30 octombrie 2026; PhraseBank de Malo et al. (2014); tweet-urile așa cum sînt publicate pe Hugging Face (seturile de antrenare și de validare).
- Fiecare model este antrenat pe procesorul central (CPU) al unui laptop, cu sămînța 20261108; seturile de test sînt folosite o singură dată.

(data/SOURCES.md)

# Cuprins


- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

# De la o frază la unități lexicale

- **O frază reală din PhraseBank**
  - "Finnish Aktia Group 's operating profit rose to EUR 17.5 mn in the first quarter of 2010 from EUR 8.2 mn in the first quarter of 2009 ."
  - Eticheta dată de adnotatori: **pozitiv**
- **Tokenizatorul nostru**
  - Litere mici, cuvinte și numere; fiecare număr devine `<num>`; legăturile și mențiunile cu @ sînt eliminate
  - Primele unități: `finnish aktia group s operating profit rose to eur <num> mn in the first` (27 în total)
- **Alegeri care schimbă rezultatele**
  - Trecerea la litere mici unește "Bank" și "bank"; reducerea la rădăcină unește "rose" și "rising"
  - Eliminarea cuvintelor de legătură șterge "not", "down", "up": dăunător pentru sentiment
- **În practică:** documentați preprocesarea și păstrați-o identică în antrenare și în producție
  - Un alt tokenizator înseamnă un alt model.

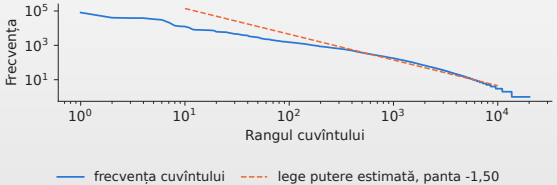
(Malo et al., 2014)

Exercițiu practic: §1

# Puține cuvinte sînt frecvente, cele mai multe sînt rare: legea lui Zipf

- **Pe scurt:** în 400 de discursuri ale Băncii Centrale Europene, frecvența scade ca o putere a rangului.

$$f(r) \approx C\, r^{-a} \quad \Longleftrightarrow \quad \ln f(r) = \ln C - a \ln r$$




Sursa: Banca Centrală Europeană, setul de discursuri. Date: 8 ianuarie 2022 - 30 octombrie 2026, 400 de discursuri.

- 1 289 896 de unități lexicale, 20 130 de cuvinte distincte
  - Panta estimată −1,498 (rangurile 10 – 10.000)
  - Cele mai frecvente 10 cuvinte reprezintă 25,0 % din total.
- 32,5 % dintre cuvintele distincte apar o singură dată: niciun model nu le poate învăța numai din acest corpus.

(Zipf, 1949; calcul propriu)

NN_L6_zipf

## Cuprins


- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

# Sacul de cuvinte: un document este un vector de frecvențe

- **Pe scurt:** ignorăm ordinea și păstrăm de cîte ori apare fiecare cuvînt din vocabular.

$$\mathbf{x}_i = (c_{i1}, \ldots, c_{iV})^\top$$

$$c_{ij} = \#\{\text{apariții ale cuvîntului } j \text{ în documentul } i\}$$

- **unde**
  - $V$ dimensiunea vocabularului (cuvintele întîlnite de cel puțin două ori în partea de antrenare)
  - Matricea documente–termeni $\mathbf{C} \in \mathbb{N}^{n \times V}$ este aproape în întregime zero

- Sacul de cuvinte (BoW) + regresia logistică multinomială este modelul de referință standard pentru text.
- $n$-gramele adaugă ordinea locală: “profit rose” și “profit fell” devin trăsături.
- Vocabularul este construit numai din frazele de antrenare.

- **În practică:** modelele BoW sînt rapide, ieftine și explicabile cuvînt cu cuvînt: auditorilor le plac.

(Salton & Buckley, 1988)

# TF-IDF: reducem ponderea cuvintelor care apar peste tot

- **Pe scurt:** un cuvînt este informativ dacă este frecvent în acest document și rar în celelalte.

$$w_{ij} = \underbrace{(1 + \ln c_{ij})}_{\text{tf}} \cdot \underbrace{\left(\ln \frac{1+n}{1+n_j} + 1\right)}_{\text{idf}}, \qquad \tilde{\mathbf{x}}_i = \frac{\mathbf{w}_i}{\|\mathbf{w}_i\|_2}$$

- **unde**
  - $c_{ij} > 0$ frecvența termenului $j$ în documentul $i$ ($w_{ij} = 0$ dacă $c_{ij} = 0$)
  - $n$ documente
  - $n_j$ documente care conțin $j$
  - Tf sublinear și idf netezit, ca în scikit-learn

- Frecvența termenului–frecvența inversă în documente (TF-IDF) pe unigrame și bigrame, apoi regresie logistică cu ponderi echilibrate ale claselor.
- Cuvinte ca “the”, “company”, `<num>` primesc un idf mic
  - “plunged” unul mare.
- Normalizarea $\ell_2$ face comparabile frazele lungi și cele scurte.

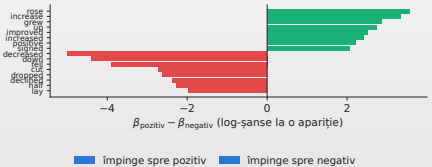
- **În practică:** TF-IDF + regresie logistică este modelul pe care orice furnizor de NLP trebuie să-l depășească pe documentele dumneavoastră.

(Salton & Buckley, 1988)

# Modelul liniar învață un dicționar al sentimentului financiar

- **Pe scurt:** diferența dintre coeficienții pozitiv și negativ ai fiecărui cuvînt, regresie logistică pe BoW, PhraseBank.

$$P(y = k \mid \mathbf{x}) = \frac{\exp(\beta_k^\top \mathbf{x} + \alpha_k)}{\sum_l \exp(\beta_l^\top \mathbf{x} + \alpha_l)}$$




Sursa: Financial PhraseBank (Malo et al., 2014). Date: 4.838 de fraze din știri financiare, 5-8 adnotatori pentru fiecare.

- Cele mai pozitive: rose, increase, grew, up, improved
  - Cele mai negative: decreased, down, fell, cut, dropped.
- Dicționarele de limbaj general interpretează greșit cuvintele financiare (“liability”, “tax”): învățați ponderile pe texte financiare.

(Loughran & McDonald, 2011; calcul propriu)

NN_L6_top_words

## Cuprins


- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

# Ipoteza distribuțională

- **Pe scurt:** cuvintele folosite în contexte asemănătoare primesc vectori asemănători; asemănarea este cosinusul unghiului.

$$\mathbf{e}_w = \mathbf{E}^\top \mathbf{o}_w \in \mathbb{R}^d, \qquad \cos(w, v) = \frac{\mathbf{e}_w^\top \mathbf{e}_v}{\|\mathbf{e}_w\| \, \|\mathbf{e}_v\|}$$

- **unde**
  - $\mathbf{o}_w \in \{0,1\}^V$ vectorul one-hot al cuvîntului $w$
  - $\mathbf{E} \in \mathbb{R}^{V \times d}$ matricea vectorilor, $d = 100 \ll V = 8\,539$
  - În cod este o căutare, nu un produs

- Vectorii one-hot sînt ortogonali: “inflation” și “prices” au cosinusul 0.
- În vectorii noștri: cos(inflation, prices) = 0,49, cos(inflation, climate) = 0,16, cos(banks, lending) = 0,46.

- **În practică:** vectorii denși permit unui model antrenat pe “profit rose” să generalizeze la “earnings increased”.

(Firth, 1957; Bishop & Bishop, 2024, sect. 12.2)

# word2vec skip-gram: prezicem contextul din cuvînt

- **Pe scurt:** fiecare cuvînt din fereastra din jurul cuvîntului central este prezis printr-un softmax peste vocabular.

$$\max_{\mathbf{U},\mathbf{V}} \frac{1}{T} \sum_{t=1}^{T} \sum_{0<|j|\leq c} \log p(w_{t+j} \mid w_t)$$

$$p(o \mid w) = \frac{\exp(\mathbf{u}_o^\top \mathbf{v}_w)}{\sum_{k=1}^{V} \exp(\mathbf{u}_k^\top \mathbf{v}_w)}$$

- **unde**
  - $\mathbf{v}_w$ vectorul de intrare (al cuvîntului central)
  - $\mathbf{u}_o$ vectorul de ieșire (al contextului)
  - $c$ raza ferestrei
  - Numitorul costă $O(V)$ pentru fiecare pereche

- **În practică:** softmax-ul peste 8 539 de cuvinte este prea lent
  - Îl înlocuim prin eșantionare negativă.

(Mikolov et al., 2013)

- Sacul continuu de cuvinte (CBOW) este varianta în oglindă: prezice cuvîntul central din media contextului.
- Rețea liniară cu un strat ascuns
  - Vectorii de cuvinte sînt prima ei matrice de ponderi.
- Corpusul nostru: 3 679 754 de perechi (cuvînt central, context) pe epocă, după subeșantionare.

# Eșantionarea negativă: deosebim perechile reale de cele aleatoare

- **Pe scurt:** înlocuim softmax-ul cu $K+1$ regresii logistice binare: un cuvînt real de context și $K$ cuvinte de zgomot.

$$\ell(w, o) = -\log \sigma(\mathbf{u}_o^\top \mathbf{v}_w) - \sum_{k=1}^{K} \log \sigma(-\mathbf{u}_{n_k}^\top \mathbf{v}_w)$$

$$n_k \sim P_n(w) \propto f(w)^{3/4}$$

- **unde**
  - $\sigma$ funcția logistică
  - $K = 5$
  - $f(w)$ frecvența în corpus
  - Cuvintele frecvente sînt păstrate cu probabilitatea $\min(1, \sqrt{t/f(w)} + t/f(w))$, $t = 10^{-4}$

- Skip-gram cu eșantionare negativă (SGNS), $d = 100$, fereastră 5, cuvinte cu cel puțin 5 apariții, Adam, 5 epoci în 120 de secunde.
- Pierderea pe pereche scade de la 2,622 (epoca 1) la 2,223.
- SGNS factorizează implicit o matrice deplasată de informație mutuală punctuală (PMI) (anexă).

- **În practică:** același truc, contrastul dintre un element real și negative eșantionate, antrenează sisteme de recomandare și reprezentări pentru detectarea fraudei.

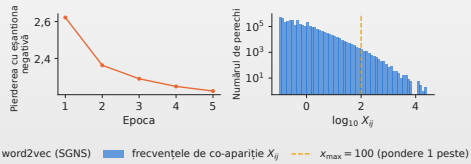
(Mikolov et al., 2013; Levy & Goldberg, 2014)

# GloVe: aproximăm logaritmul frecvențelor de co-apariție

- **Pe scurt:** numărăm o singură dată cît de des apar cuvintele împreună, apoi aproximăm logaritmii acestor frecvențe prin produse scalare, cu o pierdere de tip cele mai mici pătrate ponderate.

$$J = \sum_{i,j:\, X_{ij}>0} f(X_{ij}) \left(\mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j - \ln X_{ij}\right)^2$$

$$f(x) = \min\{1, (x/x_{\max})^\alpha\}$$




Sursa: Banca Centrală Europeană, setul de discursuri. Date: 8 ianuarie 2022 - 30 octombrie 2026, 400 de discursuri.

- **unde**
  - $X_{ij}$ co-aparițiile la cel mult 10 cuvinte distanță, ponderate cu $1/\text{distanță}$
  - $x_{\max} = 100$, $\alpha = 0{,}75$
  - Vectorul final este $\mathbf{w}_i + \tilde{\mathbf{w}}_i$

- **În practică:** 3 841 517 de perechi nenule (5,269 % din $V^2$)
  - 99,81 % sînt sub $x_{\max}$ și primesc o pondere sub 1.

(Pennington et al., 2014; calcul propriu)

NN_L6_emb_training

# Vectori de cuvinte din frecvențe: PMI și factorizarea trunchiată a matricei

- **Pe scurt:** înaintea vectorilor neuronali, vectorii denși proveneau din factorizarea unei matrice de asocieri între cuvinte.

$$\mathrm{PMI}(w, c) = \ln \frac{P(w, c)}{P(w)P(c)}$$

$$\mathbf{M}_+ \approx \mathbf{U}_d \boldsymbol{\Sigma}_d \mathbf{V}_d^\top, \qquad \mathbf{E} = \mathbf{U}_d \boldsymbol{\Sigma}_d^{1/2}$$

- **unde**
  - $P(w, c)$ ponderea co-aparițiilor lui $w$ și $c$
  - $\mathbf{M}_+$ matricea valorilor $\max(\mathrm{PMI}, 0)$
  - $\mathbf{U}_d, \boldsymbol{\Sigma}_d, \mathbf{V}_d$ primii $d$ termeni ai descompunerii în valori singulare (SVD)

- Informația mutuală punctuală (PMI) este pozitivă cînd două cuvinte apar împreună mai des decît la întîmplare.
- Tabelul nostru de co-apariții are 3 841 517 de perechi nenule, 5,269 % din cele $V^2$ celule: o matrice rară, deci SVD este ieftin.
- word2vec, GloVe și SVD-ul matricei PMI dau vecini asemănători pe același corpus.

- **În practică:** o factorizare a frecvențelor este transparentă și reproductibilă: un prim vector de cuvinte bun pentru un corpus intern.

(Levy & Goldberg, 2014)

# Cei mai apropiați vecini în vectorii noștri, învățați din discursurile băncii centrale

| Cuvîntul | word2vec (SGNS) | GloVe |
|---|---|---|
| `inflation` | headline, underlying, revert, hovering, medium | expectations, underlying, headline, core, term |
| `energy` | fertilisers, food, hicpxx, prices, renewable | prices, food, shock, commodity, renewable |
| `banks` | repaying, supervisors, themselves, obtaining, supervised | central, their, supervisors, they, have |
| `climate` | change, environmental, degradation, nature, ipcc | change, nature, environmental, related, risks |
| `digital` | convenient, functionality, kantar, erpb, payments | euro, payments, form, would, cash |
| `wages` | wage, profits, catch, negotiated, salaries | real, nominal, higher, incomes, rising |
| `ukraine` | invasion, russia, aggression, russian, brutal | invasion, russia, war, unjustified, russian |
| `rates` | interest, rate, compressed, hikes, repriced | interest, rate, short, lending, long |

- Cele mai apropiate cinci cuvinte după cosinus; ambele modele sînt antrenate pe aceleași 1 289 896 de unități lexicale din discursurile BCE; suprapunerea medie a celor două liste: 1,88 cuvinte.

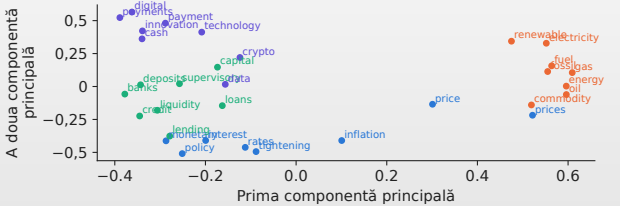
- **În practică:** un analist al politicii monetare poate extinde o căutare după “inflation” cu vecinii învățați, în locul unei liste făcute de mînă.

(calcul propriu)

**Exerciții practic:** §2

# Temele activității băncii centrale formează regiuni în spațiul vectorilor

- **Pe scurt:** proiecția bidimensională prin analiza componentelor principale (PCA) a 32 de cuvinte alese din patru grupuri; grupurile nu au fost date modelului.




Sursa: Banca Centrală Europeană, setul de discursuri. Date: 8 ianuarie 2022 - 30 octombrie 2026, 400 de discursuri.

- Două componente păstrează 31,9 % din varianța acestor 32 de vectori, deci imaginea este doar o umbră aproximativă a spațiului $\mathbb{R}^{100}$.

(calcul propriu)

NN_L6_w2v_pca

# Analogii și limitele unui singur vector pentru fiecare cuvînt

| $a : b :: c :$ ? | răspuns |
|---|---|
| germany : german : : france | fran |
| italy : italian : : spain | commissioned |
| banks : bank : : households | household |
| rise : rising : : fall | buffered |
| higher : lower : : increase | marginal |

- Răspunsul $= \arg\max_v \cos(\mathbf{e}_v, \mathbf{e}_b - \mathbf{e}_a + \mathbf{e}_c)$, excluzînd $a$, $b$, $c$; word2vec-ul nostru, un singur corpus mic.

(Mikolov et al., 2013; Bojanowski et al., 2017)

- **Vectori statici**
  - Un singur vector pentru fiecare cuvînt, indiferent de frază
  - "interest" (dobîndă) și "interest" (atenție) au același vector; la fel "bank"
- **Acoperirea**
  - Vocabularul BCE acoperă 84,7 % din unitățile lexicale din PhraseBank și 76,4 % din cele din tweet-uri
  - Restul sînt în afara vocabularului (OOV); modelele cu subcuvinte (fastText) și transformerele (cursul 7) rezolvă ambele probleme

# Vectori din subcuvinte pentru cuvintele nevăzute

- **Pe scurt:** construim vectorul unui cuvînt din vectorii *n*-gramelor sale de caractere, astfel încît un simbol bursier nou sau o greșeală de scriere primește totuși un vector.

$$\mathbf{e}_w = \sum_{g \in \mathcal{G}(w)} \mathbf{z}_g$$

- **unde**
  - $\mathcal{G}(w)$ *n*-gramele de caractere ale lui $w$ (de exemplu de 3–6 caractere, cu simboluri de margine) și cuvîntul însuși
  - $\mathbf{z}_g$ vectori învățați ai *n*-gramelor

- Acoperirea vocabularului nostru BCE la nivel de cuvînt: 84,7 % din unitățile lexicale PhraseBank, 76,4 % din cele din tweet-uri.
- Modelele cu subcuvinte (fastText) împart informația între “profit”, “profits” și “profitability”.
- Transformerele (cursul 7) folosesc aceeași idee, cu unități de subcuvinte învățate.

- **În practică:** pentru tweet-uri și mesaje, cu simboluri bursiere și variante de scriere, folosiți vectori din subcuvinte sau un tokenizator pe subcuvinte.

(Bojanowski et al., 2017)

## Cuprins


- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

# O rețea embedding bag: media vectorilor de cuvinte, apoi un softmax

- **Pe scurt:** cel mai simplu clasificator neuronal de text învață împreună vectorii de cuvinte și clasificatorul.

$$\mathbf{z} = \frac{1}{|S|} \sum_{s \in S} \mathbf{e}_s$$

$$\hat{\mathbf{p}} = \text{softmax}(\mathbf{W}\,\text{dropout}(\mathbf{z}) + \mathbf{b})$$

$$\mathcal{L} = -\frac{1}{n} \sum_i \omega_{y_i} \log \hat{p}_{i,y_i}$$

- Start aleator sau start word2vec: rîndurile lui **E** sînt inițializate cu vectorii noștri BCE, apoi ajustate.
- Comparăm și: media vectorilor word2vec + regresie logistică (vectori înghețați), TF-IDF + un perceptron multistrat (MLP) cu 128 de unități ascunse.

- **unde**
  - $S$ unitățile lexicale și bigramele frazei
  - $\mathbf{e}_s$ vectori învățați ($d = 100$)
  - $\omega_k = n/(3n_k)$ ponderi ale claselor, împotriva dominanței clasei "neutru"

- **În practică:** aceasta este arhitectura clasificatoarelor de tip fastText, folosite în producție pentru milioane de documente pe oră.

(Joulin et al., 2017)

# Regresia logistică pe text: gradientul

- **Pe scurt:** modelul logistic multinomial este o rețea cu un singur strat; gradientul lui compară probabilitățile prezise cu clasele reale.

$$\mathcal{L}(\mathbf{B}) = -\sum_i \sum_k y_{ik} \ln \hat{p}_{ik} + \frac{1}{2C}\|\mathbf{B}\|_F^2$$
$$\nabla_{\mathbf{B}}\mathcal{L} = \mathbf{X}^\top(\hat{\mathbf{P}} - \mathbf{Y}) + \mathbf{B}/C$$

- **unde**
  - $\mathbf{X}$ matricea TF-IDF ($n \times V$, rară)
  - $\mathbf{Y}$ etichetele one-hot
  - $\hat{\mathbf{P}}$ probabilitățile softmax
  - $C$ inversul penalizării, ales pe validare din $\{0{,}1; 1; 10\}$

- Pierdere convexă: un singur optim, fără sămînță de raportat
  - Perceptronul multistrat (MLP) pe aceleași intrări adaugă un strat ascuns de 128 de unități.
- Macro-F1 pe PhraseBank: logistic 73,49 %, MLP 71,37 %: stratul ascuns nu ajută aici.

- **În practică:** cu cîteva mii de fraze scurte, flexibilitatea suplimentară a unei rețele aduce variantă, nu acuratețe.

(calcul propriu)

# De la vectorii cuvintelor la vectorul frazei

- **Pe scurt:** media vectorilor de cuvinte este cea mai simplă reprezentare a unei fraze și pierde exact ce contează pentru sentiment.

$$\mathbf{s}_i = \frac{1}{|S_i|} \sum_{w \in S_i} \mathbf{e}_w, \qquad \mathbf{s}_i^{\mathrm{w}} = \frac{\sum_w a_w \mathbf{e}_w}{\sum_w a_w}, \quad a_w = \frac{\alpha}{\alpha + f(w)}$$

- **unde**
  - $S_i$ unitățile lexicale din vocabular ale frazei $i$
  - $a_w$ o pondere care micșorează influența cuvintelor frecvente
  - $\alpha$ o constantă mică

- Media vectorilor BCE înghețați + regresie logistică: macro-F1 57,30 % pe PhraseBank și 53,71 % pe tweet-uri.
- "rose" și "fell" sînt apropiate într-un spațiu de co-apariții (aceleași contexte), deci media estompează semnul.
- Ajustarea vectorilor pe date etichetate (embedding bag) recuperează cea mai mare parte a diferenței.

- **În practică:** vectorii generali sînt buni pentru căutare și similaritate, nu în mod automat pentru sentiment.

(calcul propriu)

# Protocolul și metrica: macro-F1 pentru o țintă dezechilibrată

- **Pe scurt:** clasa "neutru" reprezintă 59,3 % din PhraseBank, deci acuratețea răsplătește un model care spune mereu "neutru".

$$\mathrm{F1}_k = \frac{2P_kR_k}{P_k + R_k}, \qquad \text{macro-F1} = \frac{1}{3}\sum_{k=1}^{3} \mathrm{F1}_k$$

- **unde**
  - $P_k$ precizia și $R_k$ sensibilitatea clasei $k$
  - Fiecare clasă contează la fel, indiferent de mărime

- PhraseBank: 5 împărțiri aleatoare stratificate 70/15/15
  - Tweet-uri: setul de validare publicat, folosit ca test, 3 semințe.
- Penalizarea $C$, oprirea timpurie și vocabularul sînt alese numai pe partea de validare.

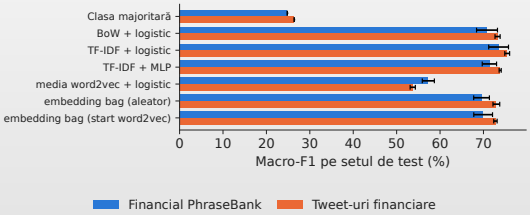
- **În practică:** pentru un sistem de alertă, raportați sensibilitatea clasei negative alături de macro-F1: aceasta este clasa care costă bani.

(calcul propriu)

**Exerciții practic:** §3

# Pe frazele financiare scurte, TF-IDF cu regresie logistică are cel mai mare macro-F1

- **Pe scurt:** macro-F1 pe test pentru șapte reprezentări și clasificatoare, PhraseBank și tweet-uri financiare (bare: media, mustăți: abaterea standard).




Sursa: Financial PhraseBank (Malo et al., 2014); Twitter financial news (Hugging Face, zeroshot). Date: PhraseBank: 5 împărțiri aleatoare 70/15/15; tweet-uri: setul de validare publicat, folosit ca test, 3 semințe.

- Pe PhraseBank: 73,49 (TF-IDF + logistic), față de 69,93 (embedding bag, start word2vec)
  - Clasa majoritară 24,81.

(calcul propriu)

NN_L6_sentiment_models

# Rezultatele pentru sentiment, cu incertitudine

| Modelul | PhraseBank macro-F1 | acur. | Tweet-uri macro-F1 | acur. |
|---|---|---|---|---|
| Clasa majoritară | $24{,}81 \pm 0{,}00$ | 59,28 | $26{,}40 \pm 0{,}00$ | 65,58 |
| BoW + logistic | $70{,}82 \pm 2{,}41$ | 74,94 | $73{,}25 \pm 0{,}59$ | 80,00 |
| TF-IDF + logistic | $73{,}49 \pm 2{,}28$ | 77,69 | $75{,}47 \pm 0{,}56$ | 81,77 |
| TF-IDF + MLP | $71{,}37 \pm 1{,}65$ | 76,23 | $73{,}85 \pm 0{,}24$ | 80,56 |
| media word2vec + logistic | $57{,}30 \pm 1{,}39$ | 62,01 | $53{,}71 \pm 0{,}60$ | 61,59 |
| embedding bag, start aleator | $69{,}56 \pm 1{,}81$ | 74,11 | $72{,}97 \pm 0{,}78$ | 79,77 |
| embedding bag, start word2vec | $69{,}93 \pm 2{,}16$ | 74,99 | $72{,}76 \pm 0{,}39$ | 79,51 |

- Pereche, pe cele 5 împărțiri PhraseBank: TF-IDF + logistic minus embedding bag (start word2vec) $= +3{,}55$ puncte, $t = 9{,}88$ (4 grade de libertate).
- Pornirea de la vectorii noștri word2vec BCE schimbă rezultatul embedding bag cu $+0{,}37$ puncte pe PhraseBank și cu $-0{,}21$ pe tweet-uri.

- **În practică:** modelul cel mai ieftin aflat la cel mult o abatere standard de cel mai bun este cel care trebuie folosit și explicat.

(calcul propriu)

# Cît de mare trebuie să fie vectorul de cuvinte?

| Dimensiunea $d$ | Macro-F1 (%) |
|---|---|
| 8 | 67,3 |
| 16 | 66,5 |
| 32 | 67,2 |
| 64 | 67,8 |
| 128 | 68,8 |
| 256 | 67,3 |

- Embedding bag, start aleator, împărțirea 1 PhraseBank, media pe 3 semințe.

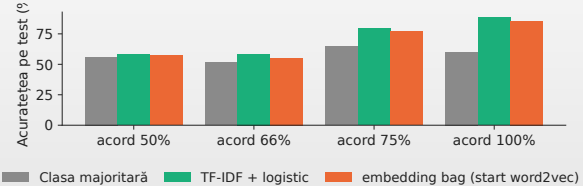
- Parametrii stratului de embedding: $V \times d$
  - Cu bigrame, $V$ are cîteva mii de elemente, deci $d$ determină mărimea modelului.
- Aici scorul variază puțin cu $d$: de la 67,3 la $d = 8$ la 68,8 la $d = 128$.
- O sarcină cu trei clase pe fraze scurte are nevoie de puține dimensiuni
  - Vectorii de uz general folosesc 100–300 pentru că servesc multor sarcini.

- **În practică:** alegeți $d$ pe datele de validare
  - Un model mai mic este mai ieftin de rulat și de explicat.

(calcul propriu)

# Erorile de clasificare și acordul adnotatorilor

- **Pe scurt:** acuratețea pe test în funcție de ponderea adnotatorilor care au fost de acord asupra etichetei frazei.




Sursa: Financial PhraseBank (Malo et al., 2014). Date: frazele de test din 5 împărțiri aleatoare, după ponderea adnotatorilor care sînt de acord.

- TF-IDF + logistic: 88,4 % pe frazele cu acord unanim, 58,1 % la un acord de 50 %
  - 2 259 din 4 838 de fraze au acord unanim.

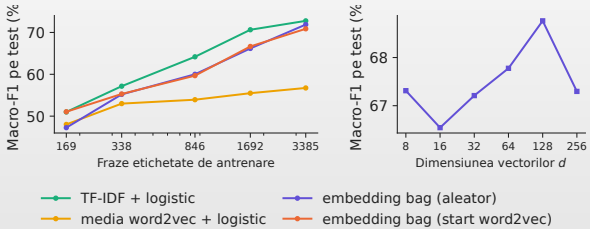
- **În practică:** zgomotul din etichete limitează orice model: înainte de a cumpăra un model mai mare, verificați cît de mult sînt de acord propriii analiști.

(calcul propriu)

NN_L6_agreement

# Cu puține etichete, startul word2vec ajută rețeaua; TF-IDF rămîne competitiv

- **Pe scurt:** stînga: macro-F1 pe test în funcție de numărul de fraze etichetate; dreapta: dimensiunea vectorilor din embedding bag.




Sursa: Financial PhraseBank (Malo et al., 2014). Date: stînga: 3 împărțiri aleatoare; dreapta: embedding bag (start aleator), împărțirea 1, 3 semințe.

- Cu 169 de fraze etichetate: TF-IDF 51,0, media word2vec 48,0, embedding bag aleator 47,2, start word2vec 51,0
  - Cu toate cele 3 385: 72,8, 56,7, 71,9, 70,9.

(calcul propriu)

NN_L6_learning_curve

# Unde sînt erorile: știrile negative citite ca neutre

| Real \ prezis | neg. | neu. | poz. |
|---|---|---|---|
| negativ | – | 107 | 48 |
| pozitiv | 50 | 263 | – |

- TF-IDF + logistic, cele 5 seturi de test PhraseBank reunite (3 635 de fraze).

- Sensibilitatea: negativ 65,9 %, neutru 84,1 %, pozitiv 69,5 %.
- Erorile de semn opus sînt rare
  - Cele mai multe erori mută fraza în clasa neutră.
- Eroare tipică: o scădere descrisă cu cuvinte neutre și cifre (“sales were EUR 10 mn, down from 12”).

- **În practică:** în finanțe, cifrele poartă sentiment
  - Înlocuirea lor cu o singură unitate pierde comparațiile de tip “down from” pe care un model secvențial le poate citi.

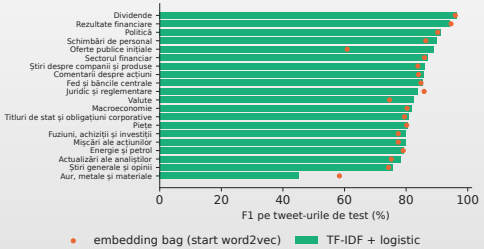
(calcul propriu)

## Cuprins


- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

# Clasificarea pe teme: F1 este mare pentru rezultate și Fed, mic pentru știrile generale

- **Pe scurt:** F1 pe fiecare temă, pentru cele 4 117 de tweet-uri de test (setul de validare publicat).




Sursa: Seturile Twitter financial news (Hugging Face, zeroshot). Date: 4.117 de tweet-uri de test (setul de validare publicat). 20 de teme.

- Macro-F1: TF-IDF + logistic 82,62 %, embedding bag (start word2vec) 80,45 %
  - Acuratețe 84,48 %, față de 20,69 % pentru tema majoritară.

(calcul propriu)

NN_L6_topic_f1

# Aplicații ale modelelor de text în finanțe

- **Triajul știrilor și al tweet-urilor**
  - Direcționarea pe teme (cea mai bună: Dividende, F1 96,4 %) și semnalarea celor negative pentru analist
- **Comunicarea băncii centrale**
  - Urmărirea cuvintelor din jurul lui “inflation” sau “energy”, discurs cu discurs
- **Conformitate și analiza de mediu, social și guvernanță (ESG)**
  - Căutarea în rapoarte cu sinonime învățate, nu cu liste fixe de cuvinte-cheie
- **Limitele modelelor de azi**
  - Ordinea cuvintelor dincolo de bigrame se pierde
  - Un singur vector pentru fiecare cuvînt ignoră contextul
  - Tema cea mai slabă: Aur, metale și materiale, F1 45,2 %
- **Urmează: atenția**
  - Vectori contextuali din transformere, de exemplu reprezentări bidirecționale ale codificatorului transformer (BERT) și un model BERT adaptat textelor financiare (FinBERT), în cursul 7, comparați corect cu aceste modele de referință

- **În practică:** începeți orice proiect de text cu TF-IDF + regresie logistică
  - Treceți la vectori de cuvinte sau transformere doar cînd cîștigul este demonstrat pe datele dumneavoastră.

(calcul propriu)

## Test 1: idf

- Un cuvînt apare în fiecare dintre cele $n$ fraze de antrenare
  - Care este idf-ul său netezit?

**Răspuns**

- $\ln \frac{1+n}{1+n} + 1 = 1$: valoarea minimă, deci aproape nu modifică vectorul normalizat.

## Test 2: eșantionarea negativă

- De ce extrage word2vec cuvintele negative din $f(w)^{3/4}$ și nu din $f(w)$?

**Răspuns**

- Puterea 3/4 aplatizează distribuția: cuvintele rare sînt extrase mai des decît frecvența lor, iar cele frecvente, ca “the”, mai rar, ceea ce dă contraste mai utile.

## Test 3: acuratețea

- Un furnizor raportează o acuratețe de 60 % pe sentimentul din PhraseBank
  - Este un rezultat bun?

**Răspuns**

- Nu: prognoza "mereu neutru" dă 59,28 %
  - Cereți macro-F1 (TF-IDF + logistic, la noi: 73,49 %).

# Test 4: transferul

- Aveți doar 169 de fraze etichetate
  - Ce reprezentare ajută cel mai mult?

**Răspuns**

- Comparați pe datele de validare: aici media word2vec dă 48,0, TF-IDF 51,0, embedding bag cu start word2vec 51,0 macro-F1.

## Test 5: polisemia

- De ce nu poate un vector static să deosebească “interest rate” de “of interest to investors”?

**Răspuns**

- Are un singur vector pentru fiecare cuvînt, media tuturor utilizărilor lui
  - Modelele contextuale (cursul 7) dau un vector diferit în fiecare frază.

# Recapitulare

- Textul ca date
- Reprezentări rare: sacul de cuvinte și TF-IDF
- Reprezentări dense: vectorii de cuvinte (embeddings)
- Clasificatoare de fraze: reprezentări rare și dense
- Studiu de caz: temele tweet-urilor financiare

- Textul devine numere prin unități lexicale și frecvențe (BoW, TF-IDF) sau prin vectori denși (word2vec, GloVe) învățați din co-apariții.
- Pe fraze financiare reale, TF-IDF + regresie logistică este modelul de depășit
  - Startul word2vec ajută rețeaua doar cînd etichetele sînt puține
  - Urmează atenția și transformerele (cursul 7).

# Cercetări ale grupului nostru: modele de limbaj în finanțe

- **Modelele lingvistice mari (LLM) prognozează valoarea expusă la risc (VaR) și pierderea medie peste VaR (ES)** (Pele, Bolovăneanu, Lin, Ren, Ginavar, Spilak, Andrei, Toma, Lessmann & Härdle, 2026, Expert Systems with Applications)
  - Lucrarea: "In the beginning was the Word: LLM-VaR and LLM-ES"; prognozele LLM sînt comparate cu modelele clasice de risc prin teste retrospective formale
  - Modelele de text trec de la scoruri de sentiment la cifrele de risc propriu-zise (cursul 12)
- **BitMood: analiza cu inteligență artificială (AI) a tendințelor Bitcoin prin emoțiile de pe Facebook** (Conda, Găman, Bâg, Mazurencu-Marinescu-Pele, Pele & Härdle, 2026, Digital Finance)
  - 120.000 de postări de pe Facebook, 2015–2023, clasificate cu FinBERT în scoruri compuse de sentiment, împreună cu reacțiile cititorilor
  - Sentimentul prognozează volumul tranzacțiilor cu Bitcoin; strategiile bazate pe sentiment depășesc strategia cumpără-și-păstrează; modelarea temelor urmărește subiectele discuției
- Rezultatele de pe acest diapozitiv sînt cele raportate în lucrări; celelalte cifre din curs provin din calculele noastre.

(Academia de Studii Economice din București; Academia Română, Institutul de Prognoză Economică)

## Lecturi și resurse suplimentare

- **Mikolov et al. (2013)** și **Pennington et al. (2014)**: cele două articole despre vectorii de cuvinte, ambele scurte.
- **Levy & Goldberg (2014)**: de ce word2vec este o factorizare de matrice.
- **Loughran & McDonald (2011)**: dicționarul de sentiment financiar și de ce eșuează dicționarele generale.
- **Acest curs**: cod, date, notebook-uri Jupyter — github.com/danpele/NEURAL_BIZ.
- **Exercițiu practic**: notebook-ul reproduce graficele acestui curs — notebooks/.
- **Seminarul 6**: un indice de sentiment al discursurilor BCE, construit cu propriul clasificator.

# Bibliografie (1/2)


- Bishop, C. M. & Bishop, H. (2024). *Deep Learning: Foundations and Concepts*, ch. 12. Springer. doi:10.1007/978-3-031-45468-4
- Bojanowski, P., Grave, E., Joulin, A. & Mikolov, T. (2017). Enriching word vectors with subword information. *TACL*, 5, 135–146. doi:10.1162/tacl_a_00051
- Conda, A. I., Găman, Ș., Bâg, R. C., Mazurencu-Marinescu-Pele, M., Pele, D. T. & Härdle, W. K. (2026). BitMood: AI analysis of Bitcoin trends via Facebook emotions. *Digital Finance*, 8(3), 42. doi:10.1007/s42521-026-00205-3
- Firth, J. R. (1957). A synopsis of linguistic theory 1930–1955. In *Studies in Linguistic Analysis*, 1–32. Blackwell.
- Joulin, A., Grave, E., Bojanowski, P. & Mikolov, T. (2017). Bag of tricks for efficient text classification. *EACL*, 427–431. doi:10.18653/v1/E17-2068
- Levy, O. & Goldberg, Y. (2014). Neural word embedding as implicit matrix factorization. *NIPS*, 27, 2177–2185. papers.nips.cc
- Loughran, T. & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *Journal of Finance*, 66(1), 35–65. doi:10.1111/j.1540-6261.2010.01625.x

# Bibliografie (2/2)


- Malo, P., Sinha, A., Korhonen, P., Wallenius, J. & Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. *JASIST*, 65(4), 782–796. doi:10.1002/asi.23062
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. *NIPS*, 26, 3111–3119. arXiv:1310.4546
- Pele, D. T., Bolovăneanu, V., Lin, M.-B., Ren, R., Ginavar, A. T., Spilak, B., Andrei, A.-V., Toma, F.-M., Lessmann, S. & Härdle, W. K. (2026). In the beginning was the Word: LLM-VaR and LLM-ES. *Expert Systems with Applications*, 295, 128676. doi:10.1016/j.eswa.2025.128676
- Pennington, J., Socher, R. & Manning, C. D. (2014). GloVe: Global vectors for word representation. *EMNLP*, 1532–1543. doi:10.3115/v1/D14-1162
- Salton, G. & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. doi:10.1016/0306-4573(88)90021-0
- Zipf, G. K. (1949). *Human Behavior and the Principle of Least Effort*. Addison-Wesley.

# Anexă: gradientul eșantionării negative

- Pentru o pereche, $\ell = -\log \sigma(s_o) - \sum_k \log \sigma(-s_k)$, cu $s_o = \mathbf{u}_o^\top \mathbf{v}_w$, $s_k = \mathbf{u}_{n_k}^\top \mathbf{v}_w$.
- Folosind $\frac{d}{ds} \log \sigma(s) = 1 - \sigma(s)$: $\partial \ell / \partial \mathbf{v}_w = -(1 - \sigma(s_o))\mathbf{u}_o + \sum_k \sigma(s_k)\mathbf{u}_{n_k}$.
- $\partial \ell / \partial \mathbf{u}_o = -(1 - \sigma(s_o))\mathbf{v}_w$ și $\partial \ell / \partial \mathbf{u}_{n_k} = \sigma(s_k)\mathbf{v}_w$: contextele reale sînt atrase, cuvintele de zgomot sînt respinse.
- La optim, $\mathbf{u}_o^\top \mathbf{v}_w = \mathrm{PMI}(w, o) - \ln K$, cu $\mathrm{PMI}(w, o) = \ln \frac{P(w,o)}{P(w)P(o)}$ (Levy & Goldberg, 2014).

# Anexă: modelele în cod

```
tf = TfidfVectorizer(ngram_range=(1, 2), min_df=2, sublinear_tf=True).fit(train_text)
clf = LogisticRegression(C=C, class_weight='balanced', max_iter=3000).fit(tf.transform(train_text), y)

class EmbBag(nn.Module):                          # fastText-style classifier
    def __init__(self, n_vocab, dim, n_cls):
        super().__init__()
        self.emb = nn.EmbeddingBag(n_vocab, dim, mode='mean')
        self.out = nn.Linear(dim, n_cls)
    def forward(self, ids, offsets):
        return self.out(F.dropout(self.emb(ids, offsets), 0.3, self.training))
# SGNS step:  loss = -(logsigmoid((v*u_pos).sum(1)) + logsigmoid(-(U_neg @
v[...,None]).squeeze()).sum(1)).mean()
```

- Codul complet: lectures/L6/analysis_L6.py și notebook-ul acestui curs.