

# Rețele neuronale și deep learning

## Cursul 11: Inteligența artificială explicabilă: SHAP, LIME, metode bazate pe gradient și stabilitatea explicațiilor



**Prof. dr. Daniel Traian PELE**

Academia de Studii Economice din București (ASE), Departamentul de Statistică și Econometrie
Academia Română, Institutul de Prognoză Economică (IPE)
IDA Institute Digital Assets ▪ AI4EFin ▪ MSCA Digital Finance

# Obiectivele cursului

- Să explicați de ce băncile, asigurătorii și autoritățile de reglementare cer explicații pentru o rețea neuronală și să clasificați metodele inteligenței artificiale explicabile (XAI).
- Să calculați explicațiile aditive Shapley (SHAP) și explicațiile locale interpretabile, independente de model (LIME), cu formulele complete, și să le interpretați pentru un client și pentru un portofoliu.
- Să folosiți metodele bazate pe gradient (saliența, gradienții integrați, SmoothGrad) și să verificați axiomele lor pe un model real de detectare a fraudei.
- Să testați dacă explicațiile sînt concordante, fidele modelului și stabile la schimbarea valorii inițiale, a eșantionului și a perioadei.
- Să formulați o explicație contrafactuală pe care un solicitant respins o poate pune în practică.

# Abrevieri

| | |
|---|---|
| **AI** | inteligență artificială |
| **AOPC** | aria de deasupra curbei de perturbare |
| **ASE** | Academia de Studii Economice din București |
| **AUC** | aria de sub curba ROC |
| **EBA** | Autoritatea Bancară Europeană |
| **EU** | Uniunea Europeană (abrevierea engleză, în citări) |
| **EUR** | euro |
| **GDPR** | Regulamentul general privind protecția datelor |
| **GNN** | rețea neuronală pe grafuri |
| **HMEQ** | setul de date privind creditele garantate cu locuința |
| **ICE** | așteptarea condiționată individuală |
| **IG** | gradienți integrați |
| **IPE** | Institutul de Prognoză Economică, Academia Română |
| **JS** | divergența Jensen-Shannon |
| **KL** | divergența Kullback-Leibler |
| **LIME** | explicații locale interpretabile, independente de model |
| **MAD** | abaterea absolută mediană |
| **MLP** | perceptron multistrat |
| **PCA** | analiza componentelor principale |
| **PD** | probabilitatea de nerambursare |
| **PDP** | graficul dependenței parțiale |
| **PICBE** | Proceedings of the International Conference on Business Excellence |
| **PR-AUC** | aria de sub curba precizie-sensibilitate |
| **ReLU** | unitate liniară rectificată |
| **ROC** | caracteristica de operare a receptorului |
| **SHAP** | explicații aditive Shapley |
| **SR** | ghidul de supraveghere privind riscul de model (Federal Reserve SR 11-7) |
| **TCAV** | testarea cu vectori de activare a conceptelor |
| **UE** | Uniunea Europeană |
| **ULB** | Université Libre de Bruxelles |
| **USD** | dolar american |
| **XAI** | inteligență artificială explicabilă |
| **XGBoost** | extreme gradient boosting (arbori amplificați prin gradient) |

# Datele reale ale cursului

| Studiul de caz | Date | Modele și împărțire |
|---|---|---|
| Credit | Setul de date privind creditele garantate cu locuința (HMEQ), 5 960 de credite, 19,9 % neplăți (Baesens et al., 2016) | perceptron multistrat (MLP), regresie logistică, extreme gradient boosting (XGBoost); 60/20/20 stratificat |
| Fraudă | Tranzacții cu carduri din setul Université Libre de Bruxelles (ULB), două zile din septembrie 2013; 281 + 211 fraude în eșantion (Dal Pozzolo et al., 2015) | MLP și regresie logistică; antrenare pe ziua 1, test pe ziua 2 |
| Locuințe | Locuințele din California, 20 640 de grupuri de locuințe din recensământul din 1990 | MLP de regresie (dependență parțială) |

- Fiecare cifră este calculată de analysis_L11.py
  - Valorile inițiale încep de la 20261108
  - Explicațiile sînt calculate pe un procesor Apple M5 Max.
- Variabilele V1–V28 de fraudă sînt componente ale analizei componentelor principale (PCA) publicate de proprietarul datelor: explicațiile numesc componente, nu cîmpuri brute.

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# Reglementările cer explicarea deciziilor automate

- **Regulamentul Uniunii Europene (UE) privind inteligența artificială (AI)** (Regulamentul 2024/1689): evaluarea bonității persoanelor fizice este cu risc ridicat (anexa III)
  - Transparență față de utilizatori (art. 13) și dreptul la explicarea deciziilor individuale (art. 86).
- **Regulamentul general privind protecția datelor (GDPR)**, art. 22 și considerentul 71: garanții față de deciziile bazate exclusiv pe prelucrarea automată.
- **Autoritatea Bancară Europeană (EBA)**, ghidul privind acordarea și monitorizarea creditelor (2020): modelele folosite la decizia de creditare trebuie să fie explicabile.
- **Riscul de model**: ghidul de supraveghere al Federal Reserve privind riscul de model (SR 11-7) cere fundamentare conceptuală, validare independentă și monitorizare continuă.
- **Motive de afaceri**: depistarea scurgerilor de informație, încrederea analiștilor de credit, explicarea unei respingeri pentru client.
- **Totuși**: o explicație este un model al modelului și poate fi greșită.

- **În practică:** o explicație care se schimbă fără ca ceva important să se schimbe este un risc de conformitate, nu o garanție.

(Regulation (EU) 2024/1689; SR 11-7)

# O clasificare a metodelor de explicare

| Metoda | Domeniu | Necesită | În acest curs |
|---|---|---|---|
| Coeficienți, grile de scor | global, intrinsec | un model liniar | reperul logistic |
| SHAP | local → global | apeluri ale modelului (Kernel); arbori (TreeSHAP) | MLP de credit, XGBoost |
| LIME | local | apeluri ale modelului | același solicitant |
| Salientă, gradienți integrați (IG), SmoothGrad | local | gradienți | MLP de fraudă |
| Graficul dependenței parțiale (PDP), așteptarea condiționată individuală (ICE) | efect global | apeluri ale modelului | MLP pentru locuințe |
| Contrafactuale | local, acționabil | gradienți sau căutare | solicitantul respins |
| Importanța prin permutare | global | etichete + apeluri ale modelului | MLP de fraudă |

- Metodele post-hoc explică o cutie neagră deja antrenată
  - Modelele interpretabile sînt transparente prin construcție (Rudin, 2019).

(Rudin, 2019)

# Studiul de caz pentru credit: compararea a trei modele de scoring

- **Pe scurt:** rețeaua ordonează rău-platnicii mai bine decît grila logistică (aria de sub curba de operare (ROC) (AUC) și aria de sub curba precizie-sensibilitate (PR-AUC) sînt mai mari); o putem explica la fel de bine?

$$\mathbf{h}_1 = \mathrm{ReLU}(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1), \quad \mathbf{h}_2 = \mathrm{ReLU}(\mathbf{W}_2\mathbf{h}_1 + \mathbf{b}_2)$$
$$f(\mathbf{x}) = \mathbf{w}_3^\top \mathbf{h}_2 + b_3, \qquad \mathrm{PD}(\mathbf{x}) = \sigma\big(f(\mathbf{x})\big)$$

- **unde**
  - $\mathbf{x}$ = 18 variabile standardizate, cu indicator pentru raportul datorie/venit lipsă (DEBTINC)
  - $f$ = log-șansele de neplată
  - 64 și 32 de unități liniare rectificate (ReLU), dropout 0,1
  - $\mathrm{PD}$ = probabilitatea de nerambursare (PD).

| Model (test) | AUC | PR-AUC | Brier |
|---|---|---|---|
| Logistic | 0,909 | 0,785 | 0,080 |
| MLP, 10 valori | 0,935 | 0,842 | 0,068 |
| XGBoost, 10 | 0,959 | 0,889 | 0,058 |

- Rata de bază (PR-AUC al unui scor aleator) 0,200.

- **În practică:** la modelul logistic coeficienții sînt explicația
  - Pentru MLP explicația trebuie calculată.

(Baesens, Roesch & Scheule, 2016; calcul propriu)

**Exercițiu practic:** notebook §1

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# Valorile Shapley: o împărțire echitabilă a prognozei între variabile

- **Pe scurt:** fiecare variabilă primește contribuția sa marginală medie pe toate ordinile în care variabilele s-ar putea alătura prognozei.

$$\phi_j = \sum_{S \subseteq \{1,\ldots,d\} \setminus \{j\}} \frac{|S|!\,(d-|S|-1)!}{d!} \Big[ v(S \cup \{j\}) - v(S) \Big]$$

- **unde**
  - $d$ = numărul de variabile
  - $v(S)$ = valoarea coaliției $S$ (ce prognozează modelul cînd sînt cunoscute doar variabilele din $S$)
  - Ponderea este ponderea ordinilor în care $j$ intră imediat după $S$.

- **Cele patru axiome** (Shapley, 1953) care fac $\phi$ unic
  - Eficiența: $\sum_j \phi_j = v(\{1..d\}) - v(\emptyset)$
  - Simetria: contribuții egale, cote egale
  - Variabila nulă: o variabilă care nu schimbă niciodată $v$ primește 0
  - Aditivitatea: $\phi(v_1 + v_2) = \phi(v_1) + \phi(v_2)$
- **Cost**: $2^d$ coaliții
  - Cu 18 variabile, $2^{18}$ evaluări ale modelului pentru fiecare solicitant: avem nevoie de aproximări.

- **În practică:** eficiența este ceea ce îi trebuie analistului de credit: părțile se adună exact la scor.

(Shapley, 1953)

# De la Shapley la SHAP: valoarea unei coaliții

- **Pe scurt:** SHAP definește $v(S) =$ ieșirea așteptată a modelului cînd variabilele din afara lui $S$ sînt extrase dintr-un eșantion de referință.

$$v(S) = \mathbb{E}_{\mathbf{x}_{\bar{S}} \sim \mathcal{B}}\left[f(\mathbf{x}_S, \mathbf{x}_{\bar{S}})\right]$$

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^{d} \phi_j(\mathbf{x}), \qquad \phi_0 = \mathbb{E}_{\mathcal{B}}[f]$$

- **unde**
  - $\mathcal{B} = 100$ de solicitanți de antrenare (referința)
  - Variabilele din afara lui $S$ sînt înlocuite independent de $\mathbf{x}_S$
  - Explicațiile sînt pe scara log-șanselor, unde efectele se adună.

- **Aditivitatea pe datele noastre**: eroarea maximă $|\phi_0 + \sum_j \phi_j - f(\mathbf{x})| =$ 2,9e-06 pe 400 de solicitanți din test.
- **Model liniar**: $\phi_j = \beta_j(x_j - \mathbb{E}x_j)$ exact (SHAP liniar).
- **Risc**: cu variabile corelate, înlocuirea independentă creează solicitanți nerealiști.

- **În practică:** eșantionul de referință definește "solicitantul mediu"
  - Documentați-l ca pe orice intrare a modelului.

(Lundberg & Lee, 2017)

**Exercițiu practic:** notebook §2

# Kernel SHAP și TreeSHAP: cum se calculează SHAP

- **Pe scurt:** Kernel SHAP estimează o regresie liniară ponderată pe coaliții eșantionate; pentru arbori valorile exacte se obțin în timp polinomial.

$$\min_{\phi} \sum_{\mathbf{z}\in\{0,1\}^d} \pi(\mathbf{z}) \left[ v(\mathbf{z}) - \phi_0 - \sum_j \phi_j z_j \right]^2$$

$$\pi(\mathbf{z}) = \frac{d-1}{\binom{d}{|\mathbf{z}|}\,|\mathbf{z}|\,(d-|\mathbf{z}|)}$$

- **unde**
  - $\mathbf{z}$ = indicatorul coaliției
  - Nucleul Shapley $\pi$ face ca soluția celor mai mici pătrate ponderate să fie egală cu valorile Shapley (Anexa A)
  - Eșantionăm 600 de coaliții pentru fiecare solicitant.

- **Kernel SHAP**: independent de model
  - 16 s pentru 400 de solicitanți.
- **TreeSHAP**: exact pentru ansambluri de arbori (Lundberg et al., 2020).
- **Rețele adînci**: Deep/Gradient SHAP combină valorile Shapley cu gradienții (secțiunea 3).

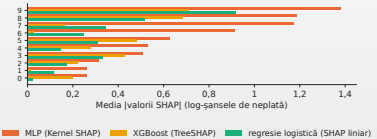
- **În practică:** Kernel SHAP are zgomot de eșantionare: documentați valoarea inițială și numărul de eșantioane.

(Lundberg & Lee, 2017; Lundberg et al., 2020)

**Exercițiu practic:** notebook §2

# Importanța globală: lipsa raportului datorie/venit domină

- **Pe scurt:** valoarea SHAP absolută medie pe variabilă, pentru rețea și cele două repere.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: 400 de solicitanți din test, 100 de solicitanți de referință.

- Pe primul loc la toate trei modelele: DEBTINC_missing
  - La MLP urmează DELINQ și JOB_Other
  - Corelația Spearman a importanțelor MLP–XGBoost 0,55, MLP–logistic 0,79.
- Raportul datorie/venit (DEBTINC) lipsește la 21,3 % dintre credite
  - Rata de neplată este 62,0 % cînd lipsește și 8,6 % cînd este raportat.

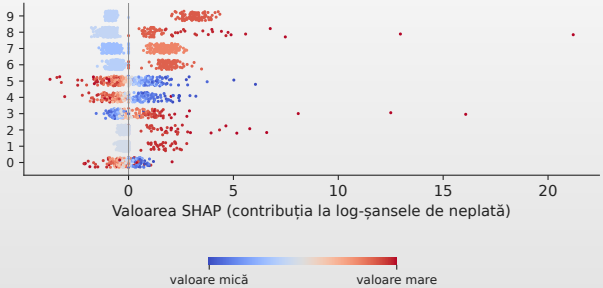
- **În practică:** o explicație poate arăta că modelul notează dosarul, nu debitorul
  - Decideți dacă acest lucru este acceptabil.

(calcul propriu)

NN_L11_shap_global

# Diagrama roi: sensul și dispersia fiecărui efect

- **Pe scurt:** fiecare punct este un solicitant; culoarea = rangul valorii variabilei; poziția = valoarea SHAP.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: 400 de solicitanți din test; culoarea = rangul valorii variabilei.

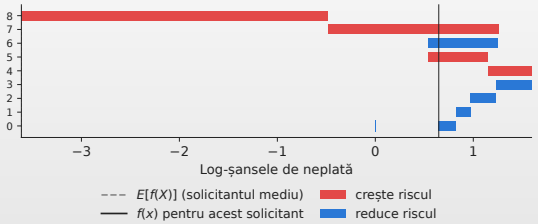
- Liniile de credit cu restanțe (DELINQ) și rapoartele negative (DEROG): valorile mari cresc riscul, așa cum se așteaptă în teoria creditului.

(calcul propriu)

NN_L11_shap_beeswarm

# De ce a fost respins acest solicitant? Diagrama cascadă SHAP

- **Pe scurt:** de la log-șansele medii $\phi_0$ la scorul acestui solicitant, variabilă cu variabilă.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: solicitant din test (rîndul 2411); valori în unitățile originale.

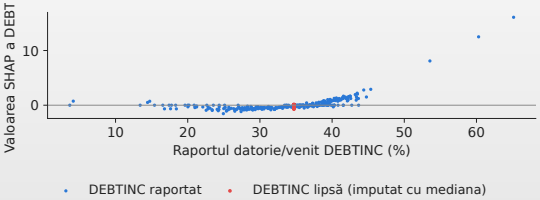
- Solicitant din test (rîndul 2411): PD 65,6 %, log-șanse $0{,}648 = -3{,}613 + 4{,}261$
  - Cele mai mari contribuții: DEBTINC_missing (+3,13), JOB_Other (+1,74), DELINQ (−0,71).

- **În practică:** notificarea de respingere enumeră principalele motive în această ordine, în cuvinte pe care clientul le înțelege.

(calcul propriu) NN_L11_shap_waterfall

# Graficul de dependență: rețeaua a învățat semnalul valorii lipsă

- **Pe scurt:** valoarea SHAP a DEBTINC în funcție de valoarea sa; punctele roșii sînt imputate cu mediana din antrenare.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: 400 de solicitanți din test, MLP.

- Solicitanții cu valoare imputată au aceeași valoare DEBTINC
  - Riscul lor este preluat de indicatorul de lipsă (SHAP mediu $+3{,}13$), nu de DEBTINC.

- **În practică:** alegerea metodei de imputare schimbă explicațiile
  - Păstrați un indicator de lipsă pentru ca motivul să poată fi numit.

(calcul propriu)

NN_L11_shap_dependence

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# LIME: un model simplu, fidel în jurul unui punct

- **Pe scurt:** solicitantul este perturbat, perturbările sînt ponderate după apropiere și se estimează un model liniar rar pe răspunsurile rețelei.

$$\xi(\mathbf{x}) = \arg\min_{g \in \mathcal{G}} \sum_{\mathbf{z}} \pi_{\mathbf{x}}(\mathbf{z}) \Big[ f(\mathbf{z}) - g(\mathbf{z}) \Big]^2 + \Omega(g)$$

$$\pi_{\mathbf{x}}(\mathbf{z}) = \exp\left( - \frac{\|\mathbf{z} - \mathbf{x}\|^2}{\sigma^2} \right)$$

- **unde**
  - $\mathcal{G}$ = modelele liniare $g(\mathbf{z}) = \beta_0 + \beta^\top \mathbf{z}$
  - $\Omega$ = penalizarea complexității
  - $\mathbf{z} \sim \mathcal{N}(\mathbf{x}, \mathbf{I})$ în unități standardizate
  - Lățimea nucleului $\sigma = 0{,}75\sqrt{d} = 3{,}18$ implicit.

- **Pantă locală**, nu o împărțire a prognozei: coeficienții nu se adună la $f(\mathbf{x})$.
- **Trei alegeri** decid rezultatul: vecinătatea, lățimea nucleului, numărul de eșantioane.
- **Solicitantul nostru**: variabila de top la LIME este DELINQ, la SHAP este DEBTINC_missing.

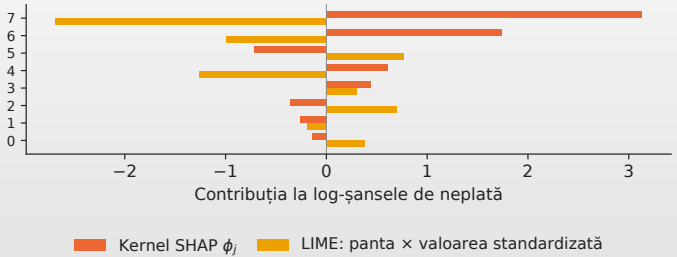
- **În practică:** LIME răspunde la "ce mișcă scorul în jurul acestui client?", iar SHAP la "de ce este acest client departe de medie?".

(Ribeiro, Singh & Guestrin, 2016)

**Exercițiu practic:** notebook §3

# LIME și SHAP pentru același solicitant

- **Pe scurt:** panta LIME înmulțită cu valoarea standardizată, alături de contribuția SHAP, pentru cele mai importante opt variabile SHAP.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: solicitant din test (rîndul 2411); LIME cu 5 000 de eșantioane.

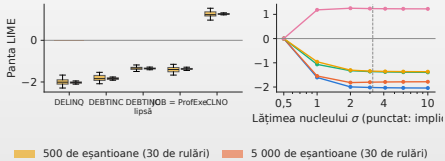
- Corelația Spearman a contribuțiilor absolute: 0,80
  - Un indicator binar este departe de aproximarea sa liniară locală.

(calcul propriu)

NN_L11_lime_vs_shap

# LIME depinde de propriile setări

- **Pe scurt:** stînga: 30 de rulări cu valori inițiale diferite; dreapta: cele cinci pante cînd se schimbă lățimea nucleului.




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: solicitant din test (rîndul 2411); dreapta: aceleași cinci variabile, 5 000 de eșantioane.

- Aceeași variabilă de top: 73 % din rulări cu 500 de eșantioane, 100 % cu 5 000
  - Suprapunerea Jaccard a primelor 5 variabile 0,72, respectiv 1,00
  - Coeficientul de variație 10 %, respectiv 2 %.

- **În practică:** fixați și raportați valoarea inițială, mărimea eșantionului și lățimea nucleului pentru orice explicație LIME care ajunge la un client sau la un auditor.

(calcul propriu)

NN_L11_lime_instability

# Explicații contrafactuale: ce ar trebui să se schimbe?

- **Pe scurt:** se caută cel mai apropiat solicitant, schimbînd doar variabile acționabile, pe care modelul l-ar accepta.

$$\mathbf{x}' = \arg\min_{\mathbf{x}'} \; \lambda \left(f(\mathbf{x}') - t\right)_+^2 + \sum_{j \in \mathcal{A}} \frac{|x'_j - x_j|}{\mathrm{MAD}_j}$$

- **unde**
  - $t$ = log-șansele-țintă ($-0{,}5$, sub pragul PD de 0,5)
  - $\mathcal{A}$ = variabilele acționabile (LOAN, DEBTINC, NINQ, DELINQ, DEROG, CLNO, MORTDUE)
  - Abaterea absolută mediană (MAD) scalează distanța
  - Valorile brute rămîn $\geq 0$, numărătorile sînt rotunjite.

| Variabila | acum | necesar |
|---|---|---|
| MORTDUE | 69 115,0 | 57 456,5 |
| DEBTINC | 34,7 | 33,4 |
| LOAN | 14 500,0 | 15 700,0 |

- PD 65,6 % → 39,2 % după aceste schimbări.
- Contrafactualul documentar: raportarea DEBTINC (la mediana 34,7) dă PD 5,1 %.

- **În practică:** "aduceți documentul de venit care lipsește" este un răspuns mai bun pentru client decît orice listă de valori SHAP.

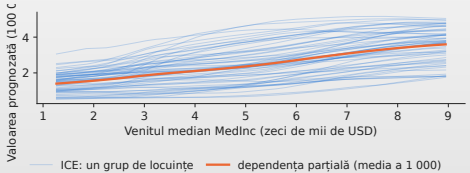
(Wachter, Mittelstadt & Russell, 2017)

**Exercițiu practic:** notebook §4

# Efecte globale: dependența parțială și ICE

- **Pe scurt:** PDP mediază prognoza pe date cînd o variabilă este fixată la o valoare din grilă; ICE păstrează cîte o curbă pentru fiecare observație.

$$\mathrm{PD}_j(z) = \frac{1}{n}\sum_{i=1}^{n} f(z, \mathbf{x}_{i,-j}), \qquad \mathrm{ICE}_{i,j}(z) = f(z, \mathbf{x}_{i,-j})$$




Sursa: StatLib, locuințe din California, recensămîntul din 1990 (Pace și Barry, 1997). Date: MLP; 60 de grupuri de test (ICE), 1 000 pentru PDP.

- MLP pentru locuințele din California ($R^2$ de test 0,819, liniar 0,620): valoarea prognozată crește de la 1,40 la 3,60 (100 000 USD) pe grila de venit
  - Dispersia curbelor ICE la capăt 0,95.

(Friedman, 2001; Goldstein et al., 2015)

NN_L11_pdp_ice

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# Studiul de caz pentru fraudă: o rețea antrenată pe ziua 1, explicată pe ziua 2

- **Pe scurt:** pentru o rețea gradienții sînt gratuiți: o singură trecere înapoi dă sensibilitatea scorului de fraudă la fiecare intrare.

$$\text{saliency}_j(\mathbf{x}) = \left| \frac{\partial f(\mathbf{x})}{\partial x_j} \right|, \qquad \text{G}\times\text{I}_j(\mathbf{x}) = (x_j - x'_j)\,\frac{\partial f(\mathbf{x})}{\partial x_j}$$

- **unde**
  - $f$ = log-șansele de fraudă ale unui MLP pe V1–V28 și logaritmul sumei
  - $\mathbf{x}'$ = referința = tranzacția legitimă medie din ziua 1
  - Ponderea clasei $\sqrt{\text{dezechilibru}}$, oprire timpurie după PR-AUC ponderat de validare.

- **Test, ziua 2** (ponderi pentru datele complete): PR-AUC MLP 0,815, logistic 0,742
  - AUC 0,961, respectiv 0,964.
- **Saturarea**: într-o zonă plată a lui $f$ gradientul este aproape zero chiar și pentru o variabilă decisivă.
- **Rețelele ReLU**: gradientul este constant pe porțiuni, deci salienta sare între regiunile liniare.

- **În practică:** un analist de fraudă primește lista ordonată a intrărilor care au declanșat alerta, în milisecunde pe tranzacție.

(Simonyan, Vedaldi & Zisserman, 2014; Dal Pozzolo et al., 2015)

**Exercițiu practic:** notebook §5

# Gradienții integrați: atribuiri care se adună

- **Pe scurt:** se integrează gradientul pe drumul drept de la referință la intrare; atribuirile se adună la $f(\mathbf{x}) - f(\mathbf{x}')$.

$$\mathrm{IG}_j(\mathbf{x}) = (x_j - x_j') \int_0^1 \frac{\partial f\left(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}')\right)}{\partial x_j}\, d\alpha$$
$$\approx (x_j - x_j') \frac{1}{m} \sum_{k=1}^{m} \frac{\partial f\left(\mathbf{x}' + \frac{k-1/2}{m}(\mathbf{x} - \mathbf{x}')\right)}{\partial x_j}$$

- **unde**
  - $m =$ pașii Riemann (regula punctului de mijloc, 64 aici)
  - Completitudinea $\sum_j \mathrm{IG}_j = f(\mathbf{x}) - f(\mathbf{x}')$ rezultă din teorema fundamentală a calculului integral pe drumuri.

- **Axiome** (Sundararajan et al., 2017)
  - Completitudinea; sensibilitatea: o variabilă care schimbă $f$ primește o atribuire nenulă
  - Invarianța la implementare: funcții egale, atribuiri egale
- **Legătura cu Shapley**: IG este valoarea Aumann-Shapley a jocului continuu de-a lungul drumului.
- **Referința contează**: "tranzacția legitimă medie" răspunde la "de ce nu este aceasta o plată normală?".

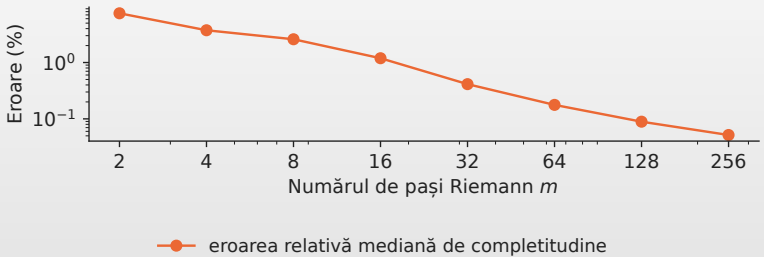
- **În practică:** scrieți referința în documentația modelului: o altă referință înseamnă o altă întrebare.

(Sundararajan, Taly & Yan, 2017)

**Exercițiu practic:** notebook §5

# Completitudinea se verifică atunci cînd integrala este calculată precis

- **Pe scurt:** mediana lui $|\sum_j \mathrm{IG}_j - (f(\mathbf{x}) - f(\mathbf{x}'))|/|f(\mathbf{x}) - f(\mathbf{x}')|$ pe fraudele din ziua 2.




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: 211 fraude din ziua a doua; referința = tranzacția legitimă medie din ziua întîi.

- Eroare de 3,7 % cu 4 pași și de 0,18 % cu 64, pe 211 de fraude
  - Eroarea scade aproximativ ca $1/m^2$, ca la regula punctului de mijloc.

(calcul propriu)

NN_L11_ig_completeness

# SmoothGrad și explicațiile la nivel de concept

- **Pe scurt:** se mediază gradienții pe copii perturbate ale intrării pentru a elimina oscilațiile ReLU; sau se testează dacă un concept uman mișcă ieșirea.

$$\mathrm{SG}_j(\mathbf{x}) = \frac{1}{n}\sum_{k=1}^{n} \frac{\partial f(\mathbf{x}+\varepsilon_k)}{\partial x_j}, \quad \varepsilon_k \sim \mathcal{N}(\mathbf{0}, s^2\mathbf{I})$$

$$S_C(\mathbf{x}) = \nabla h(\mathbf{x})^\top \mathbf{v}_C$$

- **unde**
  - $n = 50$, $s = 0{,}15$ abateri standard
  - Testarea cu vectori de activare a conceptelor (TCAV): $\mathbf{v}_C$ = normala unui clasificator liniar care separă exemplele conceptului $C$ într-un strat ascuns $h$
  - Scorul TCAV este ponderea intrărilor cu $S_C > 0$.

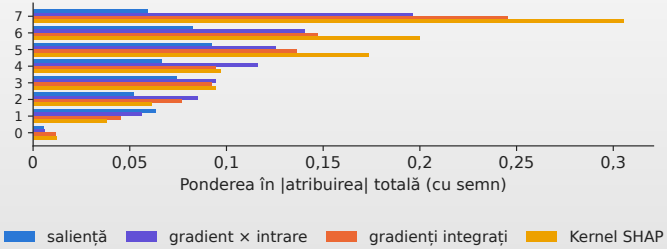
- **SmoothGrad** clarifică hărțile de salienț ale imaginilor și stabilizează gradienții tabelari (secțiunea următoare).
- **TCAV** vorbește limbajul afacerii: “tranzacție de noapte”, “comerciant nou” — dacă asemenea concepte sînt etichetate.
- **Datele noastre**: V1–V28 sînt componente anonimizate, deci aici nu se pot face teste pe concepte.

- **În practică:** explicațiile pe concepte cer concepte etichetate încă de la colectarea datelor.

(Smilkov et al., 2017; Kim et al., 2018)

# Patru metode de explicare aplicate unei tranzacții frauduloase

- **Pe scurt:** atribuirile cu semn pentru o fraudă din ziua 2 (scorul median al fraudelor), ca ponderi în atribuirea absolută totală.




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: o fraudă din ziua a doua (scorul median al fraudelor).

- Variabila de top: Kernel SHAP V14, gradienți integrați V14, salienţă V12
  - Scorul de fraudă 99,9 %: salienţa nu ține cont de mărimea abaterii față de referință.

(calcul propriu)

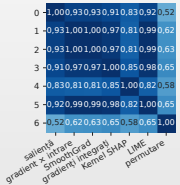
NN_L11_fraud_local

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# Concordanța metodelor: ridicată, dar nu perfectă

- **Pe scurt:** corelația Spearman a importanțelor globale (media |atribuirii|) pentru șapte metode, pe aceleași fraude.




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: corelația Spearman a importanțelor globale; 211 fraude din ziua a doua.

- IG–SHAP 0,85, salienă–SHAP 0,83, LIME–SHAP 0,82, permutare–SHAP 0,58
  - Toate metodele pun V12 pe primul loc.

- **În practică:** dezacordul este informație: importanța prin permutare arată de ce are nevoie modelul, atribuirile arată ce folosește.

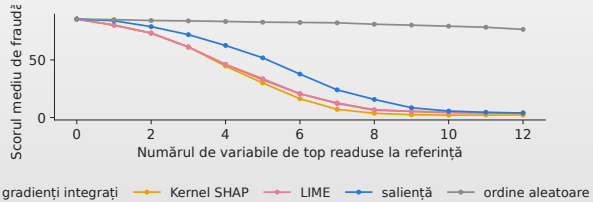
(Breiman, 2001; calcul propriu)

NN_L11_method_agreement

# Fidelitatea explicațiilor: testul eliminării variabilelor

- **Pe scurt:** variabilele de top $k$ ale fiecărei fraude sînt readuse la referință; o explicație fidelă face scorul să scadă repede.

$$\mathrm{AOPC} = \frac{1}{K} \sum_{k=1}^{K} \left[ f(\mathbf{x}) - f(\mathbf{x}^{(k)}) \right]$$




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: 211 fraude din ziua a doua.

- Aria de deasupra curbei de perturbare (AOPC), în puncte de scor de fraudă: IG 56,2, SHAP 58,4, LIME 56,1, salientă 48,0, ordine aleatoare 3,9.

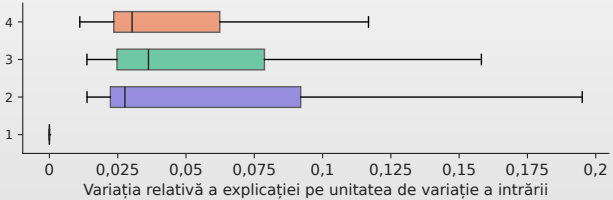
(Samek et al., 2017)

NN_L11_deletion_curve

# Robustețea locală: o mică schimbare a intrării, o mică schimbare a explicației?

- **Pe scurt:** variația relativă a vectorului de atribuiri pe unitatea unei perturbări mici (raport de tip Lipschitz).

$$\hat{L}(\mathbf{x}) = \frac{\|\mathbf{a}(\mathbf{x}+\varepsilon) - \mathbf{a}(\mathbf{x})\| / \|\mathbf{a}(\mathbf{x})\|}{\|\varepsilon\|}, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, 0.05^2\mathbf{I})$$




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: 60 de fraude din ziua a doua x 10 perturbări (sigma = 0,05 abateri standard).

- Mediane: salientă 0,000, gradient × intrare 0,028, IG 0,030, SmoothGrad 0,036
  - În interiorul unei regiuni liniare a unei rețele ReLU gradientul nu se schimbă.

(Alvarez-Melis & Jaakkola, 2018)

NN_L11_local_robustness

# Efectul Rashomon: aceeași acuratețe, explicații diferite

- **Pe scurt:** rangul fiecărei variabile după media |SHAP| pentru 10 rețele și 10 ansambluri de arbori reantrenate (doar valorile inițiale diferă).




Sursa: Baesens, Roesch și Scheule (2016), datele HMEQ. Date: 10 valori inițiale de antrenare; 200 de solicitanți din test.

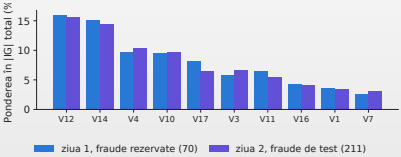
- AUC de test MLP între 0,929 și 0,941
  - Tau Kendall mediu pe perechi (acordul rangurilor importanțelor, 1 = aceeași ordine): MLP 0,83, XGBoost 0,97
  - Aceeași variabilă de top pentru un solicitant în 78 % (MLP) și 83 % (XGBoost) dintre perechile de valori inițiale.

(calcul propriu)

NN_L11_seed_stability

# Explicațiile în timp: ziua 1 față de ziua 2

- **Pe scurt:** ponderea în |IG| total pe variabile, pentru fraudele rezervate din ziua de antrenare și pentru fraudele din ziua următoare.




Sursa: ULB Machine Learning Group și Worldline, tranzacții cu carduri (OpenML 1597). Date: model antrenat pe ziua 1; gradienți integrați.

- Spearman 0,98, divergența Jensen-Shannon (JS) (construită pe divergența Kullback-Leibler (KL)) 0,003, 4 variabile comune în primele 5
  - După o zi, explicația este stabilă aici.

- **În practică:** monitorizați lunar distribuția atribuirilor, alături de distribuția scorurilor
  - O deplasare a motivelor poate preceda o scădere a acurateței.

(calcul propriu)

NN_L11_time_shift

# Fișa de stabilitate a acestui curs

| Sursa schimbării | Măsura | Rezultat |
|---|---|---|
| Aleatorismul explicației (LIME) | aceeași variabilă de top în 30 de rulări | 73 % (500), 100 % (5 000 de eșantioane) |
| Valoarea inițială (Rashomon) | tau Kendall al importanțelor globale | MLP 0,83, XGBoost 0,97 |
| Valoarea inițială, un solicitant | aceeași variabilă de top | MLP 78 %, XGBoost 83 % |
| Metoda | Spearman al importanțelor | 0,52 – 1,00 |
| Zgomotul la intrare | variația relativă mediană | IG 0,030, SmoothGrad 0,036 |
| Timpul (ziua 1 $\rightarrow$ ziua 2) | Spearman, divergența JS | 0,98; 0,003 |

⊡ **În practică:** raportați orice explicație împreună cu stabilitatea ei: ce valoare inițială, ce eșantion, ce perioadă și cît se modifică.

(calcul propriu)

## Cuprins


- De ce explicăm o rețea neuronală?
- Valorile Shapley și SHAP
- LIME, contrafactuale și efecte globale
- Metode bazate pe gradient pentru rețele neuronale
- Sînt explicațiile concordante, fidele și stabile?
- Explicabilitatea în guvernanța modelelor

# Lista de verificare pentru un audit al explicabilității

- **Scopul**: cine citește explicația (client, analist, validator, autoritate) și ce decizie susține.
- **Setările**: eșantionul de referință, referința, valoarea inițială, numărul de eșantioane, lățimea nucleului — versionate odată cu modelul.
- **Verificările**: aditivitate/completitudine, fidelitate (eliminare), stabilitate (valori inițiale, timp), concordanța a două metode.
- **Echitatea**: atribuirile variabilelor protejate și ale substitutelor lor (vîrstă, sex, cod poștal)
  - O explicație arată utilizarea, nu cauzalitatea.
- **Pentru client**: puține motive, contrafactuale acționabile, fără nume brute de componente (V14 nu înseamnă nimic pentru un client).
- **Alternativa**: dacă un model interpretabil este aproape la fel de precis (aici AUC logistic 0,909 față de MLP 0,935), luați-l în considerare.

**În practică:** raportul de validare trebuie să conțină explicațiile și testele lor de stabilitate, nu doar acuratețea.

(SR 11-7; Rudin, 2019)

# Test 1: adunarea valorilor SHAP

- Pentru solicitantul nostru valoarea de bază este $-3{,}613$, iar valorile SHAP se adună la $4{,}261$.
  - Care sînt log-șansele de neplată date de model și de ce sînteți siguri?

**Răspuns**

- 0,648: din axioma eficienței, $f(\mathbf{x}) = \phi_0 + \sum_j \phi_j$
  - PD este $\sigma(0{,}648) = 65{,}6\,\%$.

## Test 2: un LIME instabil

- Doi analiști explică același solicitant respins cu LIME și raportează motive principale diferite.
  - Este modelul inconsecvent?

**Răspuns**

- Nu neapărat: LIME eșantionează perturbări
  - Cu 500 de eșantioane variabila de top a coincis în 73 % din rulările noastre
  - Fixați valoarea inițială, creșteți eșantionul, comparați cu SHAP.

# Test 3: alegerea referinței IG

- Un coleg folosește vectorul nul ca referință pentru gradienții integrați, pe variabile de fraudă standardizate.
  - La ce întrebare răspunde explicația?

**Răspuns**

- "De ce diferă această tranzacție de tranzacția medie (inclusiv fraudele)?"
  - Referința noastră, tranzacția legitimă medie, întreabă de ce nu este o plată normală.

# Recapitulare

- **SHAP**: valori Shapley cu verificarea exactă a aditivității
  - Lipsa raportului datorie/venit determină rețeaua de credit.
- **LIME**: o pantă locală care depinde de valoarea inițială, de eșantion și de lățimea nucleului
  - Utilă, dar raportați setările.
- **Gradienți**: gradienții integrați satisfac completitudinea (eroare de 0,18 % la 64 de pași) și sînt la fel de fideli ca SHAP, la un cost mult mai mic.
- **Stabilitatea**: reantrenarea cu altă valoare inițială reordonează variabilele (tau Kendall 0,83 pentru MLP)
  - Explicațiile trebuie testate ca modelele.
- **Urmează**: cursul 12, modelele lingvistice mari, unde explicațiile devin text.

# Cercetările grupului nostru: XAI în fraudă și piețele de energie

- **Stabilitatea SHAP în detectarea fraudei cu informație din graf**: pe datele de fraudă IEEE-CIS se compară contribuțiile SHAP ale unui model XGBoost cu reprezentări dintr-o rețea neuronală pe grafuri (GNN), sub validare aleatoare și validare înainte în timp, cu un control gaussian de aceeași dimensiune și covariantă
  - Dacă modelul cu graf pare mai stabil depinde de modul în care se măsoară schimbarea, un protocol riguros pentru stabilitatea explicațiilor (Diaconu & Pele, 2026, trimis la Expert Systems with Applications; cod: QuantLet GNN_XAI_Stability).
- **Avertizarea timpurie explicabilă a vîrfurilor de preț** la energia electrică din România (Andrei, Pele, Cramer, Amza & Diaconu, 2026, Proceedings of the International Conference on Business Excellence (PICBE)) și **detectarea anomaliilor de preț cu SHAP** (Andrei & Pele, 2025, Preprints).
- **Explicabilitatea pe mai multe orizonturi** a prognozelor de preț: ce factori contează la fiecare orizont pe piața liberalizată din România (Andrei, Pele & Cramer, 2026, PICBE).
- Rezultatele sînt cele din lucrări; cifrele de pe celelalte slide-uri provin din datele noastre.

(Academia de Studii Economice din București (ASE); Academia Română, Institutul de Prognoză Economică (IPE))

# Vreți să aflați mai mult?

- **C. Molnar, Interpretable Machine Learning**, gratuit online: christophm.github.io/interpretable-ml-book.
- **Biblioteca SHAP** și exemple: shap.readthedocs.io.
- **Rudin (2019)**: argumentele pentru modele interpretabile în deciziile cu miză mare.
- **Acest curs**: cod, date, notebook-uri — github.com/danpele/NEURAL_BIZ.
- **Încercați singuri**: notebooks/L11_notebook_ro.ipynb
  - Seminarul explică un model pentru German credit, cu o verificare a echității.
- **Replicarea studiului nostru de stabilitate**: github.com/QuantLet/GNN_XAI_Stability.

# Bibliografie (1/3)


- Alvarez-Melis, D. & Jaakkola, T. S. (2018). On the robustness of interpretability methods. ICML Workshop on Human Interpretability in Machine Learning. arXiv:1806.08049
- Andrei, A.-V. & Pele, D. T. (2025). Explainable AI for electricity price anomaly detection: A SHAP-driven approach in Romania's energy market. *Preprints*. doi:10.20944/preprints202508.0410.v1
- Andrei, A.-V., Pele, D.-T. & Cramer, A.-A. (2026). Multi-horizon explainability in energy price forecasting: Disentangling market dynamics and renewable intermittency in Romania's liberalized electricity market. *Proceedings of the International Conference on Business Excellence*, 20(1), 104–117. doi:10.2478/picbe-2026-0014
- Andrei, A.-V., Pele, D.-T., Cramer, A.-A., Amza, A. & Diaconu, D. (2026). Explainable AI-based early warning system for electricity price spikes: Evidence from the Romanian market. *Proceedings of the International Conference on Business Excellence*, 20(1), 4820–4836. doi:10.2478/picbe-2026-0352
- Baesens, B., Roesch, D. & Scheule, H. (2016). *Credit Risk Analytics: Measurement Techniques, Applications, and Examples in SAS*. Wiley.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32. doi:10.1023/A:1010933404324
- Dal Pozzolo, A., Caelen, O., Johnson, R. A. & Bontempi, G. (2015). Calibrating probability with undersampling for unbalanced classification. IEEE SSCI, 159–166. doi:10.1109/SSCI.2015.33
- Diaconu, D. & Pele, D. T. (2026). SHAP stability across random and forward-time validation in graph-augmented fraud detection. Submitted to *Expert Systems with Applications*. Code: github.com/QuantLet/GNN_XAI_Stability

# Bibliografie (2/3)


- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. doi:10.1214/aos/1013203451
- Goldstein, A., Kapelner, A., Bleich, J. & Pitkin, E. (2015). Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1), 44–65. doi:10.1080/10618600.2014.907095
- Kim, B. et al. (2018). Interpretability beyond feature attribution: Quantitative testing with concept activation vectors (TCAV). ICML. arXiv:1711.11279
- Lundberg, S. M. & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. arXiv:1705.07874
- Lundberg, S. M. et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2, 56–67. doi:10.1038/s42256-019-0138-9
- Ribeiro, M. T., Singh, S. & Guestrin, C. (2016). "Why should I trust you?" Explaining the predictions of any classifier. KDD, 1135–1144. doi:10.1145/2939672.2939778
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1, 206–215. doi:10.1038/s42256-019-0048-x
- Samek, W., Binder, A., Montavon, G., Lapuschkin, S. & Müller, K.-R. (2017). Evaluating the visualization of what a deep neural network has learned. *IEEE Transactions on Neural Networks and Learning Systems*, 28(11), 2660–2673. doi:10.1109/TNNLS.2016.2599820

# Bibliografie (3/3)


- Shapley, L. S. (1953). A value for n-person games. In *Contributions to the Theory of Games II*, 307–317. Princeton University Press.
- Simonyan, K., Vedaldi, A. & Zisserman, A. (2014). Deep inside convolutional networks: Visualising image classification models and saliency maps. ICLR Workshop. arXiv:1312.6034
- Smilkov, D., Thorat, N., Kim, B., Viégas, F. & Wattenberg, M. (2017). SmoothGrad: Removing noise by adding noise. arXiv:1706.03825
- Sundararajan, M., Taly, A. & Yan, Q. (2017). Axiomatic attribution for deep networks. ICML, 3319–3328. arXiv:1703.01365
- Wachter, S., Mittelstadt, B. & Russell, C. (2017). Counterfactual explanations without opening the black box: Automated decisions and the GDPR. *Harvard Journal of Law & Technology*, 31(2), 841–887. doi:10.2139/ssrn.3063289
- Regulation (EU) 2024/1689 (Artificial Intelligence Act), *Official Journal of the European Union*, L, 12 July 2024. data.europa.eu/eli/reg/2024/1689/oj
- Board of Governors of the Federal Reserve System (2011). SR 11-7: Supervisory guidance on model risk management. federalreserve.gov

# Anexa A: de ce nucleul Shapley dă valorile Shapley

- Se impune ca $g(\mathbf{z}) = \phi_0 + \sum_j \phi_j z_j$ să satisfacă $g(\mathbf{0}) = v(\emptyset)$ și $g(\mathbf{1}) = v(\{1..d\})$ (pondere infinită pe coaliția vidă și pe cea completă).
- Ecuațiile normale ale celor mai mici pătrate ponderate cu $\pi(\mathbf{z}) \propto (d-1)/[\binom{d}{|\mathbf{z}|}|\mathbf{z}|(d-|\mathbf{z}|)]$ au soluția unică $\phi_j =$ valoarea Shapley (Lundberg & Lee, 2017, teorema 2).
- Kernel SHAP eșantionează coaliții din $\pi$ (împerecheind $\mathbf{z}$ cu $\mathbf{1}-\mathbf{z}$) și rezolvă regresia cu restricții
  - Eroarea scade ca $1/\sqrt{\text{eșantioane}}$.
- Pentru $f$ liniar și variabile independente, $v(S) = \beta_0 + \sum_{j\in S}\beta_j x_j + \sum_{j\notin S}\beta_j \mathbb{E}x_j$, deci $\phi_j = \beta_j(x_j - \mathbb{E}x_j)$.

(Lundberg & Lee, 2017)

# Anexa B: gradienții integrați ca metodă pe drum

- Pentru un drum $\gamma(\alpha)$ de la $\mathbf{x}'$ la $\mathbf{x}$: $f(\mathbf{x}) - f(\mathbf{x}') = \int_0^1 \nabla f(\gamma(\alpha))^\top \gamma'(\alpha)\, d\alpha = \sum_j \int_0^1 \partial_j f(\gamma)\, \gamma_j'\, d\alpha$.
- Dreapta $\gamma(\alpha) = \mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}')$ dă $\gamma_j' = x_j - x_j'$: fiecare termen este $\mathrm{IG}_j$, de unde completitudinea.
- Dintre metodele pe drum, dreapta este singura simetrică în raport cu variabilele (Sundararajan et al., 2017).
- Eroarea sumei Riemann cu punctul de mijloc este $O(m^{-2})$ pentru $f$ neted
  - Punctele de frîngere ReLU o încetinesc, cum arată graficul de completitudine pentru $m$ mic.

(Sundararajan, Taly & Yan, 2017)